

APACHE DORIS 3.0.8

复习题答案

第八章：高可用、容错与数据恢复

20 道综合题参考答案。每题包含一句话结论、底层因果链、得分关键词与常见误区。

配套资料：notes-08

基准版本：Apache Doris 3.0.8

整理日期：2026-08

答案导航与评分

建议先口述再核对。每题 10 分：结论 2 分，机制 4 分，故障边界 2 分，恢复证据 2 分。

题号	主题	关键词
1-5	Tablet 与副本	逻辑分片、多数派、版本完整
6-8	事务与可见性	COMMITTED、VISIBLE、Quorum
9-14	修复与扩缩容	Checker、Scheduler、Clone、Decommission
15-18	备份与 CCR	逻辑错误、RPO/RTO、异步主备
19-20	架构与诊断	共享存储、FE 多数派、影响范围

高可用题回答结构



1. Tablet 与 Replica 的区别是什么？

Tablet 是表数据的逻辑分片和调度单位；Replica 是同一 Tablet 在某个 BE/磁盘上的物理副本。

分区和分桶最终形成 Tablet ID，一个 Tablet 可以有多个 Replica。副本各自拥有 Rowset、Segment 和版本状态，FE 以 Tablet 为单位检查健康、安排 Clone 与均衡。

得分关键词

逻辑分片；物理副本；BE；Rowset；Segment；调度单位

常见误区：把 Tablet 当成一份具体文件，或把三个 Replica 理解成三个不同分桶。

2. 为什么三副本通常比两副本更适合生产集群？

三副本的多数派是 2，允许一个副本故障仍可正常多数派写入；两副本的多数派也是 2，任何一个故障都会阻断默认写入。

三副本还保留至少两个健康数据来源，有利于查询选副本与后台修复。代价是约三份原始数据之外还要支付索引、Compaction 和临时空间。它是常见成本与容错折中，不是绝对规则。

得分关键词

三副本；多数派 2；容忍 1；可靠性；存储成本

常见误区：只说三比二多一份数据，没有解释多数派数学导致的可用性差异。

3. 三副本最多可以容忍几个副本无法参与正常多数派写入？

默认多数派规则下可容忍一个，因为三副本至少需要两个成功。

$Quorum = \text{floor}(3/2) + 1 = 2$ 。一个副本故障时另两个可 ACK；两个副本故障只剩一个，不能满足多数派，写入应失败或等待恢复。读取是否还能进行还取决于剩余副本版本是否完整。

得分关键词

Quorum； $3 \rightarrow 2$ ；一个故障；读取与写入边界

常见误区：回答可容忍两个，因为还有一个副本能读；能读一份旧数据不等于能安全确认新写入。

4. 为什么四副本在多数派容错能力上不一定比三副本划算？

四副本需要三个 ACK，仍只能容忍一个写入副本故障，却比三副本多支付一份存储和维护成本。

三副本 $Quorum = 2$ ，四副本 $Quorum = 3$ ；两者最多都允许一个失败仍达到多数派。五副本 $Quorum = 3$ 才能容忍两个。偶数副本不是永远无用，但在只看多数派容错时常不经济。

得分关键词

$4 \rightarrow 3$ ； $3 \rightarrow 2$ ；同为容忍 1；奇数副本

常见误区：认为副本数每增加一个，容忍故障数就线性增加。多数派是阶梯函数。

5. BE 进程存活，为什么其上的 Replica 仍可能不能参与查询？

因为可查询还要求副本未标 BAD 且拥有完整可见版本；进程存活只说明节点能响应。

某次 Publish 或写入失败可能让副本缺少中间版本，版本链不连续。FE 在副本选择时会避开 VERSION_INCOMPLETE/BAD 副本，等待修复或重建。还需满足标签和调度约束。

得分关键词

Alive ; BAD ; 版本完整 ; Replica Selection ; VERSION_INCOMPLETE

常见误区：把 SHOW BACKENDS 的 Alive=true 当成所有 Tablet 都健康。节点健康与每个副本健康是两层状态。

6. COMMITTED 与 VISIBLE 的本质区别是什么？

COMMITTED 表示事务已经成功提交但版本可能尚未对查询发布；VISIBLE 表示后续查询可以看到新数据。

副本写入达到条件后事务进入 COMMITTED，后台 Publish Version 让受影响 Tablet 的新版本可查询，完成后转为 VISIBLE。Publish Timeout 时不要用新 Label 重导，应查询原事务最终状态。

得分关键词

事务提交 ; Publish Version ; 查询可见 ; Publish Timeout

常见误区：把 COMMITTED 当成失败或把它等同于立即可查，这两种判断都会导致错误重试。

7. Replica 缺少中间版本时，为什么不能简单读取其最新 Segment？

因为 Doris 的可见数据是连续版本变化的结果；缺少中间版本会使最终逻辑状态不完整。

Replica 有 v1、v2、v4 但缺 v3，v4 并不一定包含 v3 的全部变化。尤其更新、删除和聚合语义依赖完整版本链。系统应把它标为不完整并从健康副本补齐或重建。

得分关键词

连续版本 ; 缺口 ; 更新删除 ; VERSION_MISSING ; 修复

常见误区：把版本号看成互相独立的完整快照。Rowset 版本通常表示增量变化，不是每次全量复制。

8. 多数派写入为什么比等待全部副本拥有更好的写入可用性？

它允许少数慢副本或故障副本不阻断提交，同时仍让新数据存在于相交的多数集合中。

等待全部时整体由最慢副本决定；只等一个又可能因唯一最新副本损坏而丢已确认数据。多数派在故障容忍与可靠性间折中，未成功副本之后由后台修复。

得分关键词

慢副本 ; 可用性 ; 相交多数 ; 异步修复 ; 可靠性折中

常见误区：把多数派解释成单纯减少延迟。它更重要的目标是故障下仍能安全推进。

9. Tablet Checker 与 Tablet Scheduler 分别负责什么？

Checker 发现并分类副本健康问题；Scheduler 根据优先级和资源安排 Repair、Balance、Clone 与迁移。

Heartbeat 提供节点存活信号，Checker 比较期望副本数、版本和位置，生成 Missing、Incomplete、Relocating 等状态。Scheduler 再选择健康源、目标 BE/磁盘和执行槽位。

得分关键词

Heartbeat ; Checker ; Scheduler ; 健康分类 ; Clone

常见误区：认为 Checker 自己搬数据，或把 Scheduler 只理解成查询调度器。

10. 为什么不应在短暂网络抖动后立即执行大量全量 Clone ?

因为原节点可能很快恢复，立即重建会制造无用磁盘与网络流量，并挤压查询、导入和 Compaction。

修复系统需要在数据风险和资源稳定间折中，通常结合故障持续时间、优先级、磁盘水位和调度槽位。若每次 10 秒抖动都复制数百 GB，修复行为本身会成为第二次故障。

得分关键词

瞬时故障；延迟修复；Clone 流量；资源竞争；二次故障

常见误区：认为越早复制越安全，忽略恢复成本与故障是否持续。

11. ADMIN REPAIR TABLE 为什么不能保证一定修复成功？

因为它只是提高指定表或分区的调度优先级，不能创造健康源副本、空间或合法目标位置。

若所有副本都坏、目标磁盘达到高水位、标签/Colocate 无解、Scheduler 被关闭或 Clone 一直超时，优先级再高也无法执行。应结合 pending_tablets、sched_stat 和 Tablet Diagnosis 找真实阻塞。

得分关键词

优先级；健康源；目标容量；标签；Scheduler；诊断

常见误区：把 ADMIN REPAIR 当作同步强制修复命令，执行后就认为数据已恢复。

12. 新增一台 BE 后，为什么查询性能不一定立即提升？

因为存算一体模式下新 BE 初始没有 Tablet，本地扫描能力要等副本逐步迁移后才能充分参与。

ADD BACKEND 只注册节点，Tablet Scheduler 需要在网络与磁盘限额内 Clone/Balance。迁移过程还与查询、导入和 Compaction 竞争 IO，所以短期甚至可能出现波动。

得分关键词

空 BE；Tablet 迁移；Balance；本地扫描；IO 竞争

常见误区：把扩容理解成 CPU 立即加入所有查询。数据位置是存算一体架构中的硬条件。

13. DECOMMISSION BACKEND 与 DROP BACKEND 有什么本质区别？

DECOMMISSION 先安全迁移副本再移除节点；DROP 立即删除节点元数据，不保证数据迁移。

Decommission 是异步过程，可观察 SystemDecommissioned 和 TabletNum，必要时取消。Drop 可能直接移除一健康副本，因此生产环境通常选择前者。

得分关键词

安全迁移；异步；TabletNum；立即删除；数据风险

常见误区：认为二者只是速度不同。真正差异是是否先满足副本安全。

14. 三节点、三副本集群为什么无法直接安全下线其中一台 BE？

因为剩余两台已经各有该 Tablet 的一个副本，又没有第四台满足副本异机放置，旧节点上的第三副本无处迁移。

Decommission 必须先在其他合适 BE 创建替代副本。三节点三副本已经占满所有候选主机，直接移走一台只能把副本数降为二。因此应先增加新 BE 并准备容量，再执行缩容。

得分关键词

三节点三副本；无目标；异机约束；先扩后缩

常见误区：认为剩余两台空间足够就能各放两个同 Tablet 副本；同主机副本不能提供独立故障隔离。

15. 为什么三个数据副本仍然无法防止误执行 DROP TABLE？

因为 DROP 是合法元数据操作，会一致作用到所有副本；副本只防止部分物理副本损坏，不保存独立历史。

DELETE、错误覆盖和上游坏数据也会被正常提交并复制。要恢复逻辑错误，需要独立时间点 Backup，或在错误尚未复制/覆盖前使用其他历史源；多副本不是备份。

得分关键词

逻辑错误；一致执行；历史时间点；Backup；多副本不是备份

常见误区：认为三副本意味着随时能从某个副本找回旧表；副本通常保持同一当前状态。

16. RPO 与 RTO 分别表示什么？

RPO 是最多可接受丢失多少时间的数据；RTO 是故障后多长时间必须恢复服务。

一天一次备份可能带来接近 24 小时 RPO；有快照但恢复 6 小时，则 RTO 至少受 6 小时限制。RPO 由备份频率、CCR Lag 和上游回放决定，RTO 由数据量、带宽、Tablet、BE 与校验决定。

得分关键词

Recovery Point Objective；Recovery Time Objective；频率；恢复演练

常见误区：把 RPO 当恢复耗时、RTO 当丢失窗口，或只写目标不进行真实恢复演练。

17. 为什么 CCR 不能被理解成两个集群之间的任意双向写入？

CCR 的核心是源到目标的异步复制和灾备，不是为同一逻辑表提供自动冲突解决的多主写入。

目标按源 Binlog 应用事务/SQL。若源、目标同时独立产生更新，历史会分叉，切回时无法简单判断顺序与赢家。切换前应封锁源写、等待 Lag、校验并只在目标开放写入。

得分关键词

异步主备；Binlog；单写；历史分叉；切换封锁

常见误区：认为有两个集群就天然等于 Active-Active，忽略冲突和回切问题。

18. 为什么启用了 CCR 后仍然需要独立备份？

因为合法误删除和错误写入也会被 CCR 同步到目标；备份才提供独立历史时间点和长期保留。

CCR 主要应对集群或机房故障并降低 RPO，延迟决定未复制数据窗口。Backup 应与生产权限和故障域隔离，可在错误同步后仍恢复旧版本。两者职责互补。

得分关键词

逻辑错误复制；历史时间点；CCR Lag；Backup；权限隔离

常见误区：把灾备副本当离线归档；只要持续同步，它通常也会持续接收坏操作。

19. 存算一体和存算分离模式下，BE 故障的意义有什么不同？

存算一体 BE 同时持有权威 Tablet 副本，故障会损失计算和一份持久数据；存算分离 BE 主要是无状态计算与缓存，权威数据在共享存储。

前者要靠多副本和 Clone 恢复，扩缩容伴随数据迁移；后者可更轻量替换计算节点，但会丢缓存并产生冷启动。HA 重心转向 FE、Meta Service、元数据存储和共享对象存储，备份仍不可少。

得分关键词

权威数据；本地副本；共享存储；无状态 BE；缓存冷启动

常见误区：认为存算分离等于没有状态和没有故障风险；状态只是移动到共享存储与元数据层。

20. 当 SELECT 正常但 DDL 和导入全部失败时，应优先检查什么，为什么？

应优先检查 FE 是否存在 Master、Follower 是否形成多数派以及 Journal 状态，因为只读查询可能继续，而元数据写和事务提交需要领导者与多数派。

先执行 SHOW FRONTENDS，观察 IsMaster、Role、Alive、ReplayedJournalId，再检查入口是否路由到正确 FE。BE 和 Tablet 若普遍正常却只有写控制面失败，更符合 FE 选举或多数派问题。

得分关键词

FE Master；Follower 多数派；Journal；SHOW FRONTENDS；控制面

常见误区：先重启全部 BE 或执行 Tablet Repair；症状范围已经指向 FE 控制面。

综合自测标准

完成第八章后，应能从影响范围判断入口、FE、BE、Tablet、事务或容灾层，并明确多副本、Backup 与 CCR 各自不能解决什么。

能力层级	合格表现	优秀表现
故障模型	知道 FE/BE 冗余	能按进程、主机、机架和机房划分失败域
一致性	知道三副本	能解释多数派、版本缺口和可见状态
修复	会看 Tablet Health	能判断无源、无目标、容量和调度阻塞
容灾	知道备份和 CCR	能量化 RPO/RTO 并设计切换、回切与恢复验证
诊断	会看 SHOW FRONTENDS/BACKENDS	能按影响范围保留证据并避免扩大故障

参考资料

[1] Doris 3.x Tablet Repair and Balance

[2] Doris 3.x Load High Availability

[3] Doris 3.0 Elastic Scaling

[4] Doris 3.x CCR Overview

[5] Release 3.0.8