

APACHE DORIS 3.0.8

复习题答案

第九章：Catalog、数据湖与联邦查询

15 道综合题参考答案。每题包含一句话结论、底层因果链、得分关键词与常见误区。

配套资料：notes-09

基准版本：Apache Doris 3.0.8

整理日期：2026-08

答案导航与评分

建议先口述再核对。每题10分：概念边界2分，底层链路4分，性能或一致性边界2分，架构判断2分。

题号	主题	关键词
1-4	Catalog与Hive	命名空间、HMS、分区裁剪、缓存
5-8	湖表格式	Snapshot、Manifest、Delete、COW/MOR、LSM
9-12	联邦与性能	JDBC、缓存、CBO、全局快照
13-15	架构选择	TVF、内表、小文件、冷热分层

Catalog题回答结构



1. Catalog 与连接器有什么区别？

连接器是访问某类系统的底层实现，Catalog 是一个有名字、已配置、可授权的数据源实例与命名空间。

例如HMS连接器定义怎样访问Hive Metastore和文件，hive_prod Catalog则保存HMS地址、存储配置和认证，并把库表暴露为hive_prod.db.table。一个实现可以服务多个不同配置的Catalog。Catalog只建立映射和访问入口，不会自动复制源数据。

得分关键词

连接实现；命名实例；连接属性；三段式名称；不复制数据

常见误区：把Catalog等同于一个JAR驱动，或认为CREATE CATALOG会把外部表导入Doris。

2. 为什么 Hive 表的数据通常不在 Hive Metastore 中？

Hive Metastore保存表结构、分区、格式和Location，真实业务行通常位于HDFS或对象存储文件中。

HMS相当于目录系统，描述orders有哪些列、按dt分区、数据位于哪个路径以及使用Parquet还是ORC。Doris FE从HMS获得这些说明，BE再直接读取文件，大量数据不经过HMS。这种元数据与数据分离也让Spark、Trino和Doris能共享同一张表。

得分关键词

HMS；Schema；Partition；Location；HDFS/S3；BE直读

常见误区：认为Hive进程或HMS数据库中保存了全部Parquet数据，因而查询数据必须经过HMS中转。

3. HDFS 出现新分区目录后，Doris 为什么可能看不到？

因为文件系统目录、HMS分区登记和Doris元数据缓存是三层独立状态，任一层未更新都可能不可见。

只创建dt=2026-08-19目录不一定向HMS执行ADD PARTITION；HMS已登记后，Doris还可能命中旧的分区列表缓存。应先确认文件存在，再查HMS元数据，最后按最小粒度REFRESH TABLE或等待缓存刷新，而不是盲目重启集群。

得分关键词

文件状态；HMS登记；分区列表缓存；REFRESH TABLE；分层排查

常见误区：看到HDFS目录就断言表必须能查询，或不检查HMS便反复刷新整个Catalog。

4. Hive 分区裁剪与 Doris 分桶裁剪有什么区别？

Hive分区裁剪依据外部表分区元数据和目录排除文件集合；Doris分桶裁剪依据内表Tablet的Hash分布排除部分Tablet。

WHERE dt='2026-08-18'可让Hive Catalog只选择对应分区路径；Doris内表若按user_id Hash分桶，等值条件可定位相关Bucket/Tablet。前者主要服务数据生命周期和粗粒度目录裁剪，后者同时承担集群数据分布、并行度与Join局部性。

得分关键词

Partition；目录/文件；Bucket；Hash；Tablet；并行分布

常见误区：把Hive目录分区与Doris Hash分桶都称为分片，忽略它们在数据分布和调度上的不同职责。

5. Iceberg 为什么需要 Snapshot 和 Manifest ?

Snapshot定义某时刻表的文件集合，Manifest分层记录文件及统计信息，使并发提交、Time Travel和文件裁剪不再依赖盲目列举目录。

Snapshot先指向Manifest List，Manifest再描述Data/Delete File及分区和列统计。一次提交生成新元数据并原子切换当前快照，旧快照仍可用于历史查询。优化器还能先根据Manifest排除不可能命中的文件，避免打开全部对象。

得分关键词

Snapshot ; Manifest List ; Manifest ; 文件集合 ; 原子提交 ; Time Travel ; 裁剪

常见误区：把Snapshot理解成复制了一份完整数据，或认为Manifest本身包含所有业务行。

6. Iceberg Delete File 为什么会增加查询成本？

删除信息与基础数据分开保存时，读取端必须同时扫描并匹配Delete File，才能还原当前快照中的有效行。

Position Delete按数据文件和行位置删除，Equality Delete按键值匹配删除。它们减少写入时重写大Parquet文件的成本，但查询时需要额外IO、内存集合或Join式匹配；Delete File过多会形成读放大，因此需要Rewrite/Compaction将删除效果合并回新数据文件。

得分关键词

Position Delete ; Equality Delete ; 读时合并 ; 读放大 ; Rewrite/Compaction

常见误区：认为逻辑删除只改一个元数据位，对读取没有任何代价。

7. Hudi COW 和 MOR 分别把主要成本放在哪里？

COW把更多成本放在写入时重写Base File，MOR把更新先写Log，把部分成本推迟到查询合并和后台Compaction。

COW产生可直接读取的新Parquet，因此Snapshot Query较简单，但频繁小更新可能写放大。MOR保留Base File并追加增量Log，写入更轻；Read Optimized可只读Base但可能不含最新变化，Snapshot Query则需合并Base与Log。

得分关键词

Copy On Write ; Merge On Read ; Base File ; Log ; 写放大 ; 读时合并 ; Compaction

常见误区：只说COW适合读、MOR适合写，却没有说明成本如何在写入、查询和Compaction之间转移。

8. Paimon 为什么更适合 Flink 流式湖仓？

Paimon把主键更新、Changelog、Snapshot和LSM式Compaction设计为核心，适合Flink持续写入和流批统一读取。

流任务不断产生增量文件，Paimon用Snapshot记录一致文件集合，并通过LSM层级和Compaction把许多小更新整理成稳定文件。Changelog还能服务下游增量消费。Doris 3.0.8在此架构中主要扮演高性能查询引擎，而不是替代Flink完成全部持续写入语义。

得分关键词

Flink ; 主键更新 ; Changelog ; Snapshot ; LSM ; Compaction ; 查询引擎

常见误区：把Paimon仅当作另一种Parquet目录，忽略其流式更新和变更日志设计。

9. 为什么 JDBC Catalog 不能把 MySQL 大表自动变成 MPP 查询？

Doris可以并行处理回传结果并下推部分条件，但数据仍由MySQL扫描并经JDBC和网络传输，源库瓶颈不会凭空消失。

大表查询受MySQL索引、磁盘、CPU、连接数和事务负载约束。无法下推的表达式还会让源库返回更多行，再由Doris过滤。JDBC适合小维表、低频核对和少量导入；高并发大分析应通过Binlog/Flink CDC把数据同步到Doris内表。

得分关键词

谓词下推；源库扫描；JDBC吞吐；网络；小维表；CDC

常见误区：认为只要SQL从Doris发起，远程MySQL就自动获得多个BE的本地分片和副本。

10. 元数据缓存和数据缓存分别位于哪里、缓存什么？

元数据缓存主要在FE，缓存Schema、分区、快照和文件列表；Data Cache主要在BE本地磁盘，缓存远程文件的数据块。

前者减少HMS或Catalog RPC，但可能使新表、新分区短暂不可见，可按Catalog/Database/Table刷新。后者减少HDFS/S3重复IO，依赖热点、SSD和足够空间，对JDBC这类非文件外表无效。REFRESH TABLE刷新元数据，不等价于清除BE文件缓存。

得分关键词

FE；Schema/Partition/Snapshot；BE；文件块；时效性；命中率

常见误区：把两种缓存都理解成查询结果缓存，或认为REFRESH CATALOG会清除所有BE数据块。

11. 为什么外表统计信息会影响 Broadcast 与 Shuffle 选择？

CBO根据行数、NDV和过滤选择率估算Join两侧规模，错误统计会让大表被误判为小表并选择错误的数据分布方式。

Broadcast需要把一侧复制到所有参与BE，适合小表；Shuffle按Join Key重分布两侧数据，网络更大但能处理大表。若十亿行外表被估成十万行，Broadcast可能造成网络和内存爆炸。应检查SHOW TABLE STATS，并按3.0支持边界收集外表统计信息。

得分关键词

CBO；row count；NDV；选择率；Broadcast；Shuffle；内存

常见误区：认为Broadcast或Shuffle完全由SQL写法固定，与统计信息和过滤后基数无关。

12. 跨 Catalog 查询为什么不能自动提供全局一致快照？

每个外部系统有独立事务、快照和读取时刻，Doris能统一执行计划，但没有跨HMS、Iceberg和MySQL的全局事务协调器。

Iceberg可能固定在10:00快照，MySQL连接在10:01读到更新，Hive文件还可能由另一任务提交。最终Join结果可能不对应任何单一全局时刻。财务结算等强一致任务应先把各源固化到明确批次、同一快照或同一存储系统，再开始计算。

得分关键词

独立事务；读取时刻；Snapshot；无全局协调；批次固化；一致性边界

常见误区：因为SQL在同一个Doris会话中执行，就假设所有外部源自动共享一个事务时间点。

13. Catalog、TVF 和导入内表分别适合什么场景？

Catalog适合反复查询有正式元数据的外部表，TVF适合临时读取文件，内表适合高频、高并发、低延迟且需要完整Doris优化能力的负载。

Catalog不复制数据，保留外部所有权；TVF在SQL里直接给URI、格式和认证，无需长期对象；导入或CTAS会复制数据并可设计分区、分桶、排序、索引和物化视图。选择关键不是数据能否读取，而是复用频率、服务SLA、源系统压力和一致性要求。

得分关键词

长期外表；临时文件；数据复制；SLA；索引；物化布局

常见误区：把三者只按SQL写法选择，不考虑重复访问、外部依赖和高并发服务成本。

14. 为什么治理小文件通常应优先从数据生产端入手？

小文件问题源于物理布局，Doris只能优化枚举和扫描，不能在查询时无代价地把远端百万对象永久合并。

每个小文件都可能带来元数据、对象存储请求、Scan Split、调度和打开关闭成本。增加BE只会让更多节点共同承担碎片化开销。应由Spark Rewrite、Iceberg/Hudi/Paimon Compaction或Flink写入参数把文件整理为合理尺寸，Doris侧缓存和并发参数只能缓解。

得分关键词

物理布局；对象请求；Scan Split；规划开销；Compaction；源头治理

常见误区：认为调高扫描线程或增加BE能从根本上消除百万小文件的元数据和IOPS成本。

15. 如何设计 Doris 热点数据与 Iceberg 历史数据的冷热分层？

把近期、高并发、低延迟数据保存在Doris内表，把长期历史保存在Iceberg，通过Catalog做低频全历史分析，并建立明确的时间边界与统一口径。

例如最近30天订单由Flink写Doris，五年历史写Iceberg；BI默认查Doris，月度复盘通过Iceberg Catalog读取历史，必要时与Doris维表Join。应避免冷热时间重叠导致重复统计，定义迁移水位、回补、晚到数据和一致性校验，并让高频外部维表通过CDC进入Doris。

得分关键词

热点内表；历史Iceberg；Catalog；时间边界；晚到数据；去重；CDC维表

常见误区：只画两套存储却不定义时间水位、重复数据、回补规则和查询路由，最终产生口径不一致。

综合自测标准

完成第九章后，应能把任意外表查询拆成对象解析、元数据获取、文件或远端SQL裁剪、BE扫描、网络Exchange和最终计算，并能判断何时应停止调参、改为同步内表或治理源端文件。

能力层级	合格表现	优秀表现
概念	知道Catalog查询外部表	能区分Catalog、连接器、TVF与内表
底层链路	知道FE/BE分工	能分开元数据路径和数据路径
湖表	知道三种格式名称	能解释Snapshot、Manifest、Timeline和LSM的成本转移
优化	会写分区条件	能用EXPLAIN/Profile定位Split、IO、统计和Join问题
架构	知道冷热分层	能定义时间水位、一致性边界和查询SLA

参考资料

- [1] Doris 3.x Data Catalog Overview
- [2] Doris 3.x Hive Catalog
- [3] Doris 3.0 Iceberg Catalog
- [4] Doris 3.0 Hudi Catalog
- [5] Doris 3.0 JDBC Catalog
- [6] Doris 3.0 Metadata Cache
- [7] Doris 3.0 External Table Statistics
- [8] Release 3.0.8